《大数据技术原理与应用》实验一报告

题目：	Hadoop 集群的安装与配置	姓名：	陈嘉豪	日期：	2026 年 5 月 11 日
实验环境：	Ubuntu Kylin 16.04 LTS、VMWare Workstation 17、Hadoop 3.3.5、JDK 1.8.0_371				
实验内容与完成情况：	完成 Linux 虚拟机安装、常用 Linux 命令练习、Hadoop 单机/伪分布式/完全分布式配置，成功运行 MapReduce 分布式作业。				
出现的问题：	VMWare Tools 下载失败、FTP 中文乱码、apt 源报错、JAVA_HOME 未生效、SSH 免密登录失败（sign_and_send_pubkey）、PID 文件残留、MRAppMaster 找不到等。				
解决方案：	1. FTP 乱码 → 安装 FileZilla 指定 GBK 编码 2. apt 源报错 → 清除旧源修复 DNS 3. JAVA_HOME → hadoop-env.sh 写死路径 4. SSH 免密 → 手动启动 ssh-agent 并加载私钥 5. PID 残留 → 清理 /tmp/*.pid 后重启 6. MRAppMaster → mapred-site.xml 添加 HADOOP_MAPRED_HOME 全部问题均已解决。				

一、实验目的

1. 掌握 Linux 虚拟机的安装方法
2. 掌握常用的 Linux 命令操作
3. 掌握 Hadoop 的分布式安装与配置方法
4. 掌握 Hadoop 的常用操作（HDFS 文件操作、MapReduce 作业运行）
5. 掌握 Hadoop 完全分布式集群的搭建方法

二、实验环境

项目	配置
操作系统	Ubuntu Kylin 16.04 LTS
虚拟机软件	VMWare Workstation 17
Hadoop 版本	3.3.5
JDK 版本	1.8.0_371
集群规模	2 台虚拟机（1 Master + 1 Slave）
Master 节点	主机名：master，IP：192.168.88.128，角色：NameNode、ResourceManager
Slave 节点	主机名：slave1，IP：192.168.88.132，角色：DataNode、NodeManager

三、实验内容与步骤

3.1 安装 Linux 虚拟机

在 VMWare Workstation 中创建两台 Ubuntu Kylin 16.04 LTS 虚拟机，配置硬盘 100GB（动态分配）、内存 8GB。安装完成后安装 VMware Tools 以支持共享文件夹和分辨率调整。

遇到的问题：无法直接通过 VMWare Workstation 下载 VMware Tools；Ubuntu 访问 Windows FTP 服务器时中文文件名乱码。

解决方法：通过 sudo apt install filezilla -y 安装 FileZilla，强制指定 GBK 编码连接 FTP，从 Download 目录获取 VMware Tools 安装包。共享文件夹无法使用时，改用 scp 命令在 Windows 宿主机和虚拟机之间传输文件。

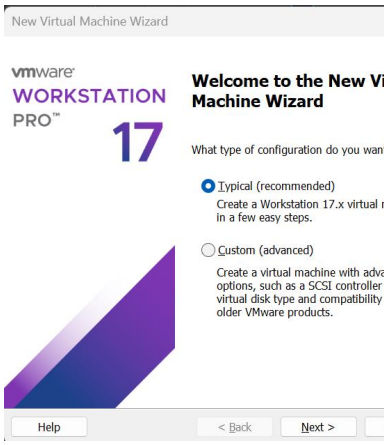

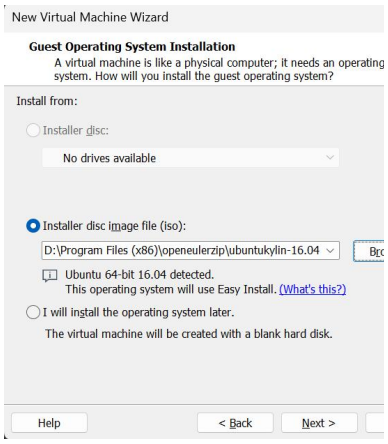

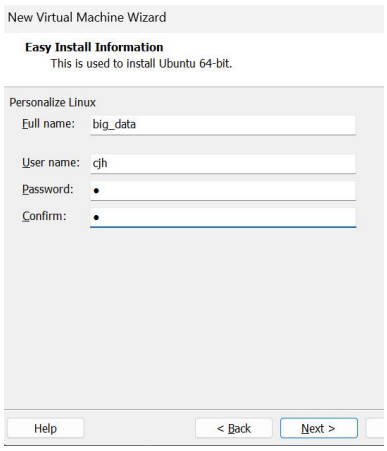

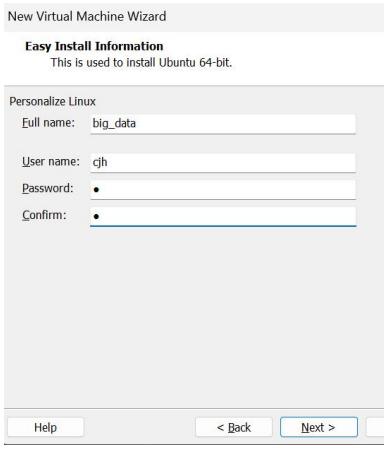

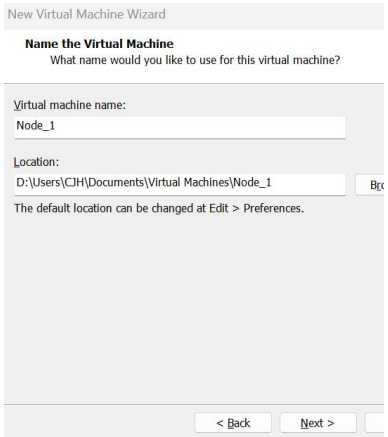

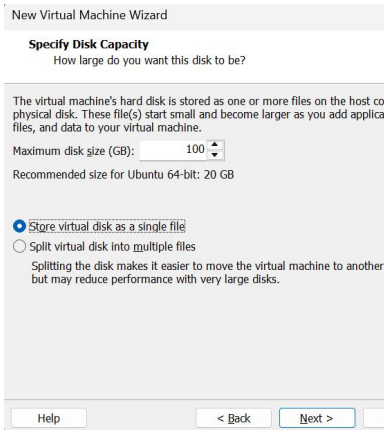

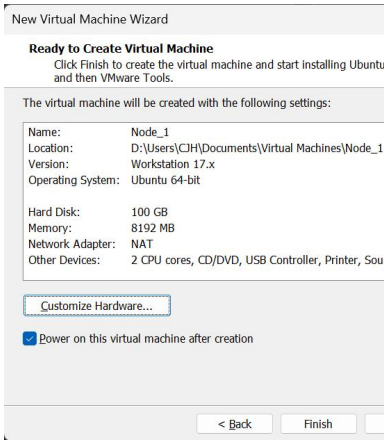

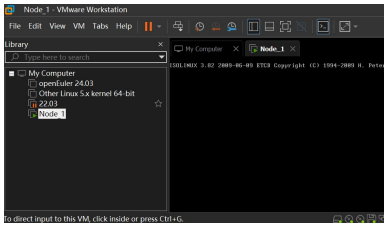

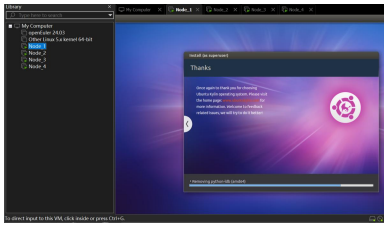

3.2 熟悉常用的 Linux 操作

在终端中练习了 19 个常用 Linux 命令，包括：

类别	命令
目录操作	cd、ls -al、mkdir、rmdir
文件操作	cp、mv、rm、touch
查看内容	cat、tac、more、head、tail
权限管理	chown、chmod
其他	find、tar、grep、环境变量配置

通过实际操作掌握了 Linux 文件系统的基本管理方法。

Linux 文件系统目录结构

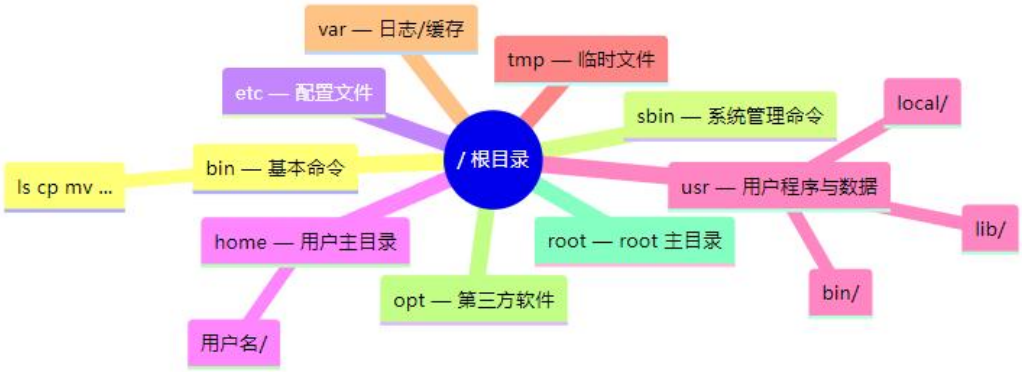

文件操作命令关系图

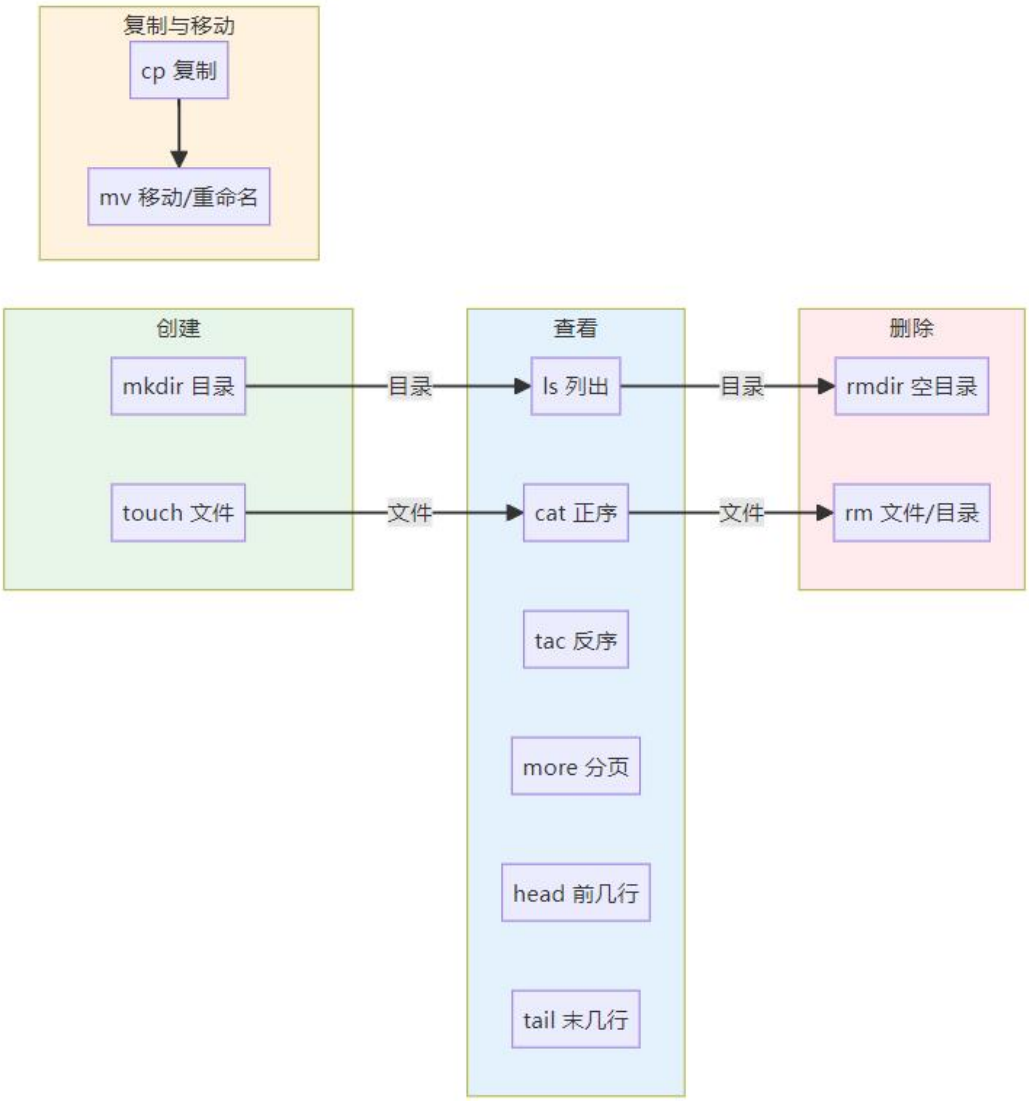

chmod 权限数字对照表

数字	权限	含义
7	rwx	读+写+执行
6	rw-	读+写
5	r-x	读+执行
4	r--	只读
0	---	无权限

tar 压缩与解压流程

参数	含义
z	gzip 压缩
c	创建（create）
x	解压（extract）
v	显示过程（verbose）
f	指定文件名（file）
C	指定解压目标目录

用户与权限管理

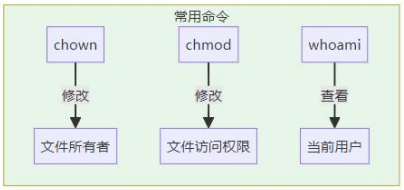

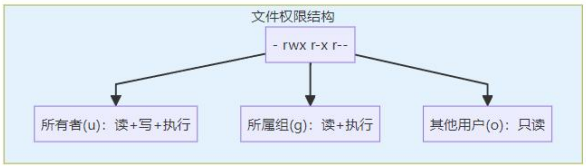

Linux 常用命令思维导图

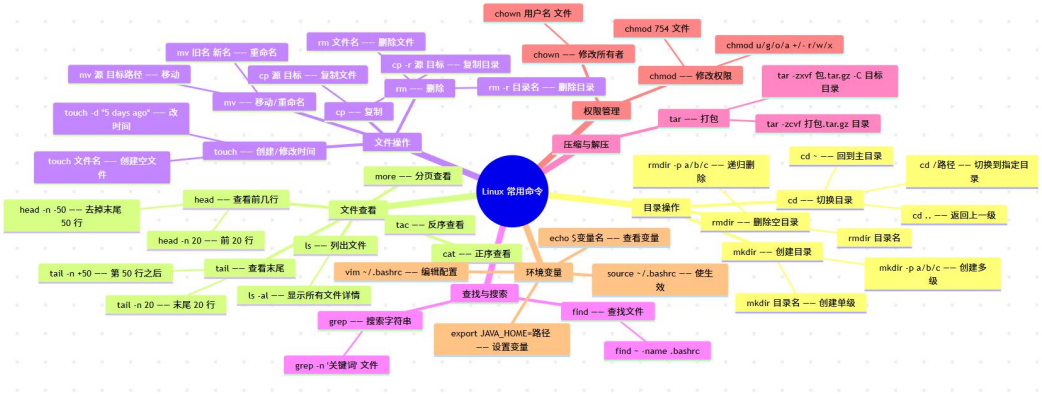

3.3 进行 Hadoop 安装

（1）创建 hadoop 用户

```
sudo useradd -m hadoop -s /bin/bash
sudo passwd hadoop
sudo adduser hadoop sudo
```

（2）基础环境配置

更新 apt 并安装 vim。

遇到的问题：apt update 执行报错，原因是 sources.list 中残留旧版本源。

解决方法：清除 ubuntukylin 旧源，修复 DNS 解析，重新执行 apt update。

（3）安装 SSH 并配置免密登录

安装 openssh-server，生成密钥并配置本机免密登录。

（4）安装 Java 环境

从 Windows 宿主机通过 scp 传输 JDK 安装包到虚拟机，解压到 /usr/lib/jvm 并配置 JAVA_HOME 环境变量。

遇到的问题：JAVA_HOME 路径正确但运行时显示 JAVA_HOME is not set。

解决方法：在 hadoop-env.sh 中将 export JAVA_HOME=${JAVA_HOME} 改为具体的路径。

（5）安装 Hadoop 3.3.5

将 Hadoop 解压到 /usr/local/hadoop，修改文件权限。

3.4 Hadoop 单机配置（非分布式）

Hadoop 默认以单机模式运行。运行附带的 grep 示例，成功输出 dfsadmin 出现 1 次。

3.5 Hadoop 伪分布式配置

修改 core-site.xml，设置 fs.defaultFS 为 hdfs://localhost:9000；修改 hdfs-site.xml，设置 dfs.replication 为 1。格式化 NameNode 后启动，验证显示 NameNode、DataNode、SecondaryNameNode 三个进程。在 HDFS 上运行 MapReduce 作业成功。

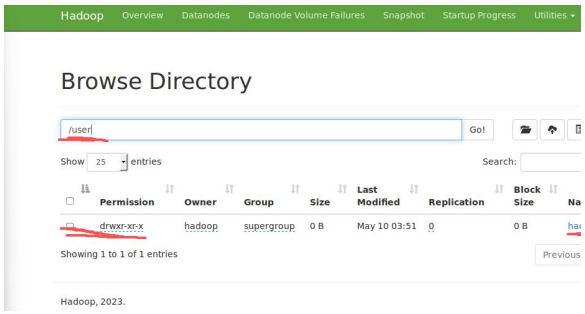

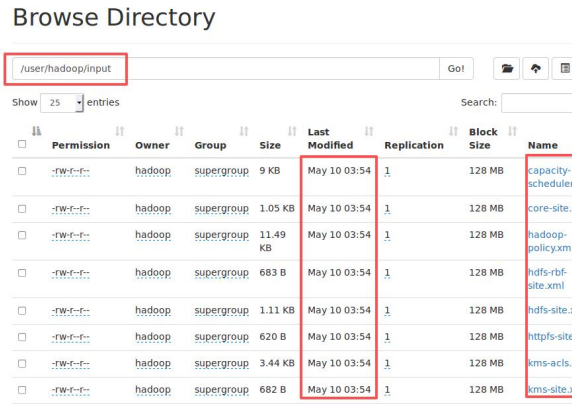

3.6 Hadoop 安装流程图

3.6.1 整体安装流程

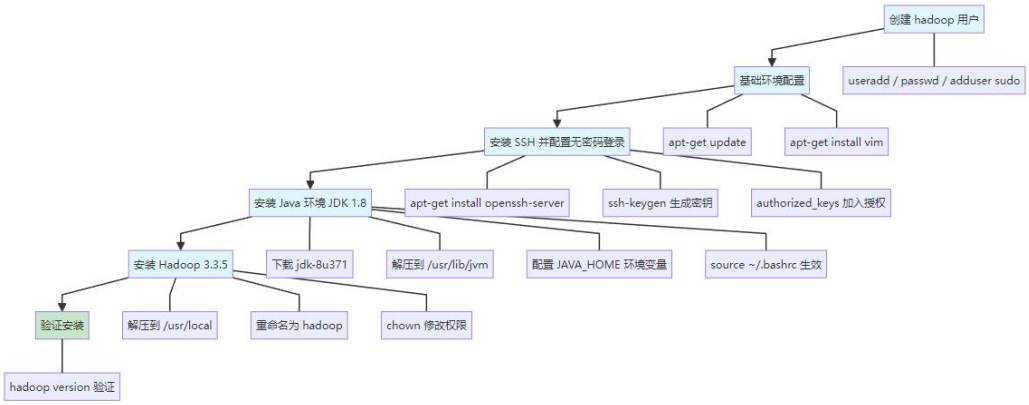

3.6.2 Hadoop 目录结构

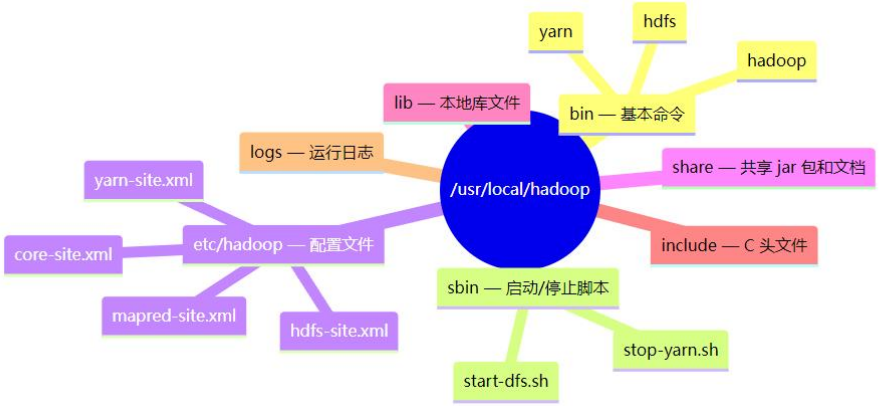

3.6.3 环境变量配置说明

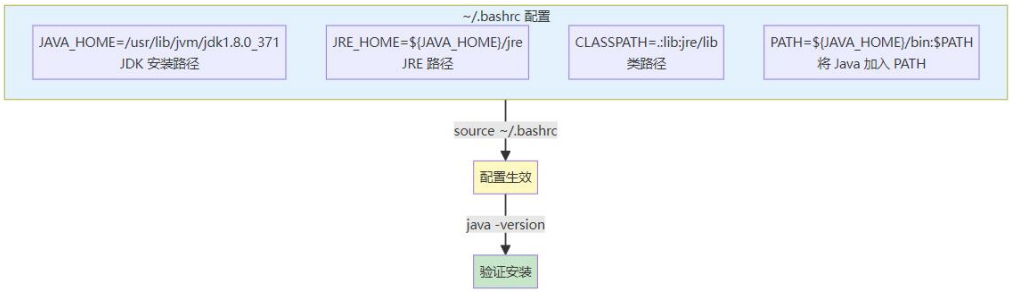

3.7 Hadoop 完全分布式配置（两台虚拟机）

（1）介绍

在单节点上完成伪分布式配置后，本节搭建由两台虚拟机组成的 Hadoop 完全分布式集群。

```
hadoop@ubuntu:~$ ifconfig
ens33     Link encap:Ethernet  HWaddr 00:0c:29:ef:e9:76
          inet addr:192.168.88.128  Bcast:192.168.88.255  Mask:255.255.255.0
          inet6 addr: fe80::f6a0:7688:b25a:cf5b/64 Scope:Link
          UP BROADCAST RUNNING MULTICAST  MTU:1500  Metric:1
          RX packets:431 errors:0 dropped:0 overruns:0 frame:0
          TX packets:125 errors:0 dropped:0 overruns:0 carrier:0
          collisions:0 txqueuelen:1000
          RX bytes:66784 (66.7 KB)  TX bytes:12313 (12.3 KB)

lo        Link encap:Local Loopback
          inet addr:127.0.0.1  Mask:255.0.0.0
          inet6 addr: ::1/128 Scope:Host
          UP LOOPBACK RUNNING  MTU:65536  Metric:1
          RX packets:7 errors:0 dropped:0 overruns:0 frame:0
          TX packets:7 errors:0 dropped:0 overruns:0 carrier:0
          collisions:0 txqueuelen:1
          RX bytes:387 (387.0 B)  TX bytes:387 (387.0 B)
```

与伪分布式的区别

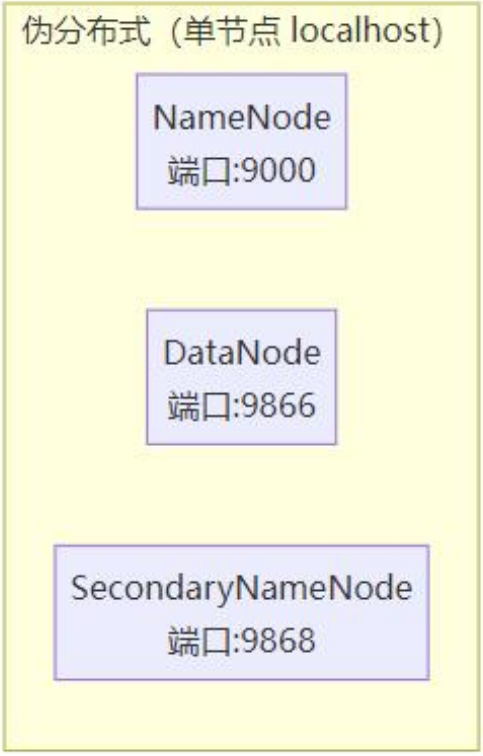

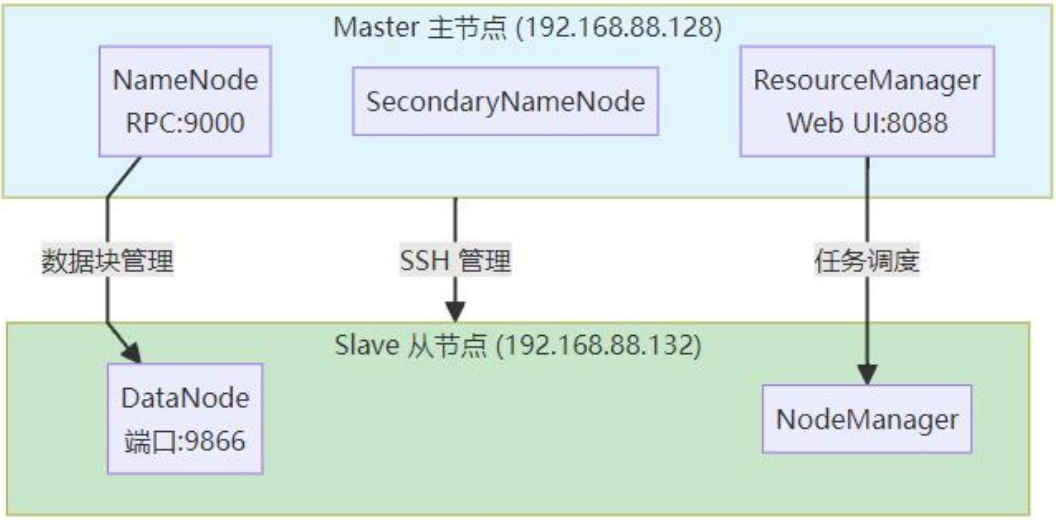

对比项	伪分布式	完全分布式
节点数量	1 台	2 台（1 Master + 1 Slave）
fs.defaultFS	hdfs://localhost:9000	hdfs://Master:9000
dfs.replication	1	2
workers 文件	不需要 / localhost	需要配置 Slave 主机名
SSH 免密登录	localhost → localhost	Master → Slave

（2）规划网络与主机名

节点	主机名	IP	角色
Master	master	192.168.88.128	NameNode、ResourceManager
Slave	slave1	192.168.88.132	DataNode、NodeManager

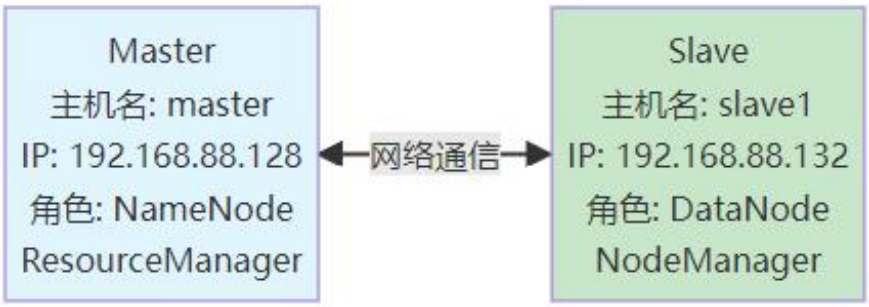

（3）配置 SSH 免密登录

遇到的问题：配置 SSH 免密登录时出现 sign_and_send_pubkey: signing failed: agent refused operation 错误。

解决方法：Ubuntu 16.04 默认不会自动启动 ssh-agent，需要手动执行 eval "$(ssh-agent -s)" 和 ssh-add ~/.ssh/id_rsa。

完整流程：清空旧密钥 → 生成新密钥 → 启动 ssh-agent → 加载私钥 → 配置对自己免密 → 配置对 Slave 免密。

（4）修改 Hadoop 配置文件【Master 节点】

在 Master 上修改 6 个配置文件，然后通过 scp 分发到 Slave：

配置文件	关键配置
core-site.xml	fs.defaultFS = hdfs://master:9000
hdfs-site.xml	dfs.replication = 2
yarn-site.xml	yarn.resourcemanager.hostname = master
mapred-site.xml	mapreduce.framework.name = yarn + HADOOP_MAPRED_HOME
workers	slave1
hadoop-env.sh	export JAVA_HOME=/usr/lib/jvm/jdk1.8.0_371

（5）分发配置到 Slave

```
scp -r /usr/local/hadoop hadoop@slave1:/usr/local/
scp ~/.bashrc hadoop@slave1:~/
```

（6）格式化并启动集群

```
./bin/hdfs namenode -format
./sbin/start-dfs.sh
./sbin/start-yarn.sh
```

遇到的问题：从节点报 xxx is already running 错误。

解决方法：清理 PID 文件后重新启动。

（7）验证集群状态

Master 上 jps 显示 NameNode、ResourceManager、SecondaryNameNode；Slave 上显示 DataNode、NodeManager。

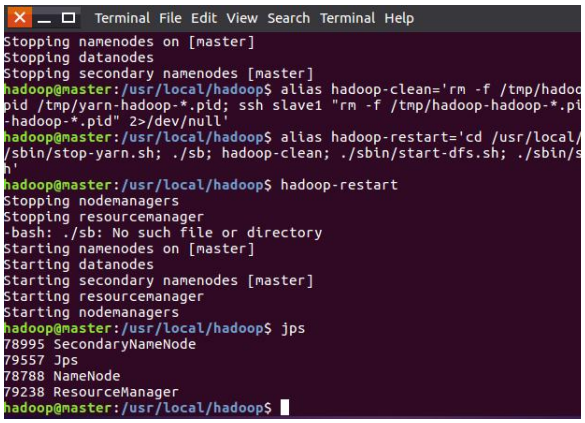

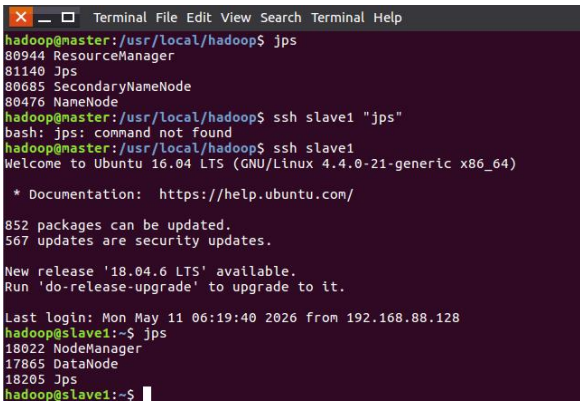

（8）运行分布式 MapReduce 作业

遇到的问题：运行 MapReduce 任务时报错 Could not find or load main class MRAppMaster。

解决方法：在 mapred-site.xml 中补充 HADOOP_MAPRED_HOME 环境变量配置，同步到 Slave 并重启集群后成功运行。

```
Terminal File Edit View Search Terminal Help
                Merged Map outputs=1
                GC time elapsed (ms)=0
                Total committed heap usage (bytes)=1550843904
        Shuffle Errors
                BAD_ID=0
                CONNECTION=0
                IO_ERROR=0
                WRONG_LENGTH=0
                WRONG_MAP=0
                WRONG_REDUCE=0
        File Input Format Counters
                Bytes Read=219
        File Output Format Counters
                Bytes Written=77
hadoop@master:/usr/local/hadoop$ . -cat output/*
-bash: .: -c: invalid option
.: usage: . filename [arguments]
hadoop@master:/usr/local/hadoop$ ^C
hadoop@master:/usr/local/hadoop$ ./bin/hdfs dfs -cat output/*
1       dfsadmin
1       dfs.replication
1       dfs.namenode.name.dir
1       dfs.datanode.data.dir
hadoop@master:/usr/local/hadoop$
```

（9）监控系统资源与作业执行情况

通过 Web 界面和命令行监控集群状态：

http://192.168.88.128:9870 <- HDFS 状态

http://192.168.88.128:8088 <- YARN 状态

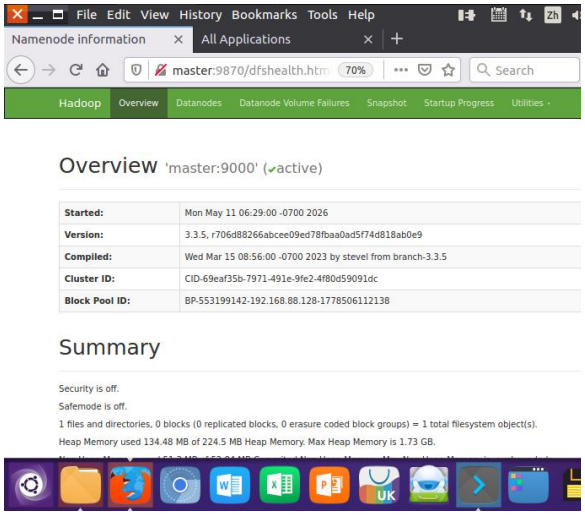

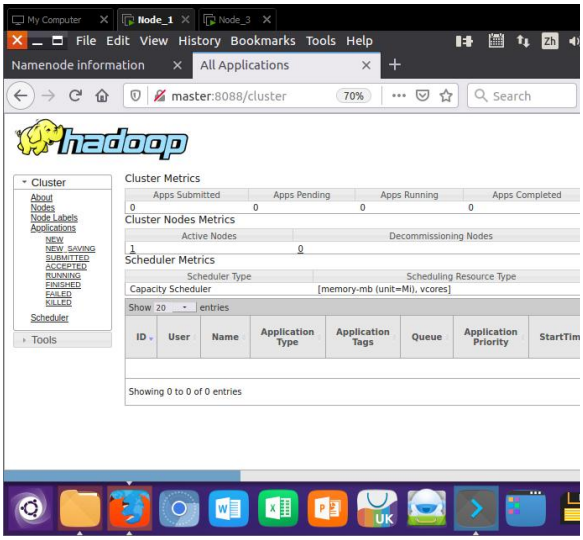

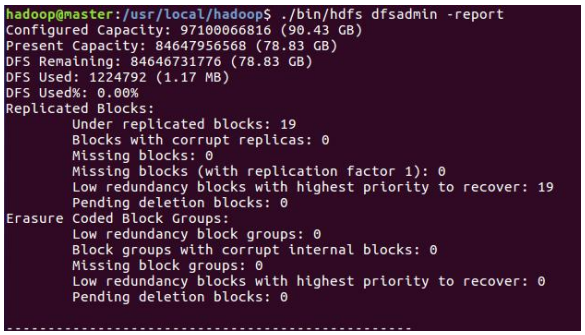

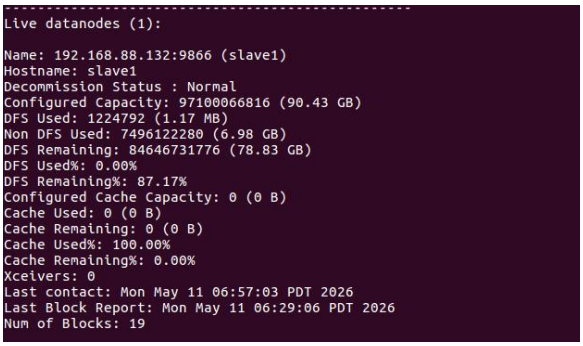

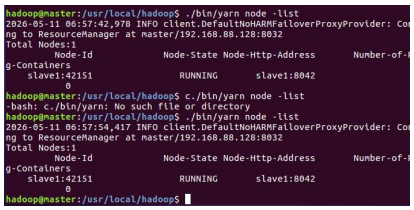

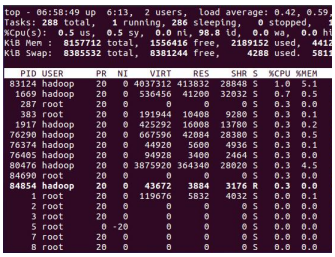

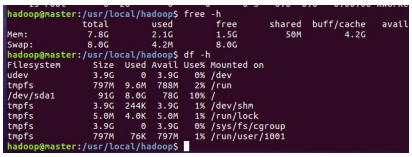

（10）关闭集群

```
./sbin/stop-yarn.sh
./sbin/stop-dfs.sh
```

关闭顺序与启动顺序相反——先停 YARN，再停 HDFS。

四、实验结果与分析

1. 单机模式：成功运行 grep 示例，本地文件系统读写正常，输出 dfsadmin 出现 1 次。

2. 伪分布式模式：成功在 HDFS 上运行 MapReduce 作业，三个核心进程正常运行。

3. 完全分布式模式：成功搭建两节点集群，MapReduce 任务被调度到集群上执行，数据块以副本数 2 分布在两个节点上。

五、遇到的问题及解决方法汇总

序号	问题	原因	解决方法
1	VMWare Tools 无法下载，FTP 中文乱码	FTP 编码不匹配	安装 FileZilla，指定 GBK 编码
2	apt update 报错	sources.list 残留旧源	清除旧源，修复 DNS
3	共享文件夹无法使用	VMWare Tools 安装问题	改用 scp 传输文件
4	JAVA_HOME is not set	hadoop-env.sh 未写死路径	改为具体路径
5	SSH 免密 sign_and_send_pubkey 失败	ssh-agent 未启动	手动启动 ssh-agent 并加载私钥
6	从节点报 already running	PID 文件残留	清理 /tmp/*.pid 后重启
7	MRAppMaster 找不到	mapred-site.xml 缺少环境变量	添加 HADOOP_MAPRED_HOME
8	Web UI 无法访问	IP 地址不一致	使用正确的 Master IP

问题一详细说明

连接 FTP 后仍出现编码错误无法正确定位文件，因此安装 FileZilla 并强制指定 GBK 编码。

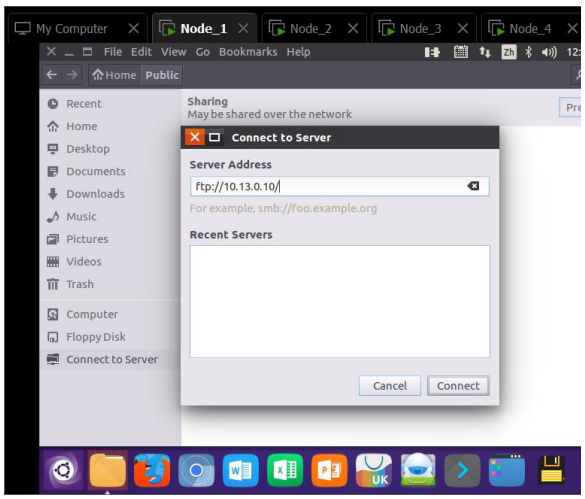

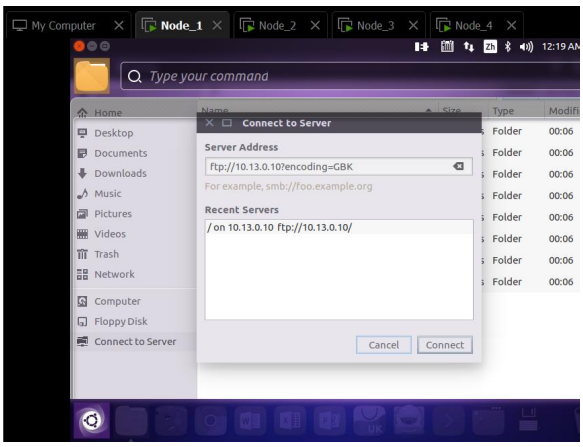

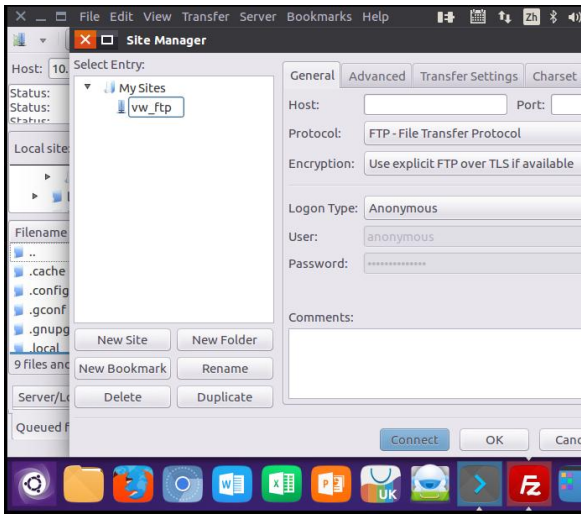

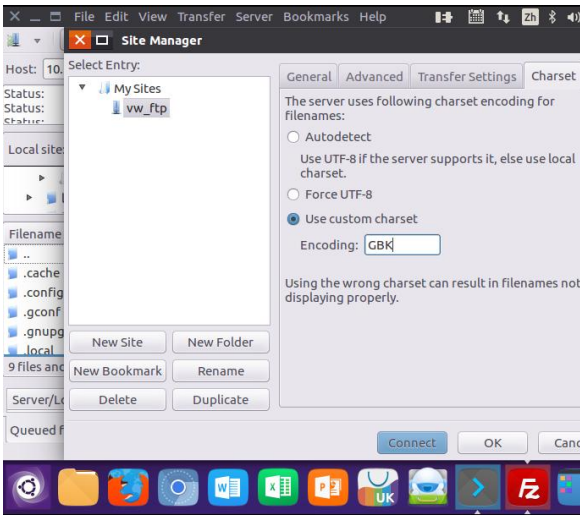

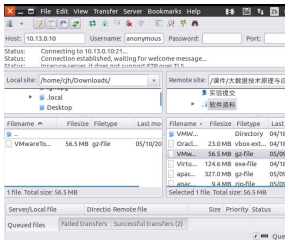

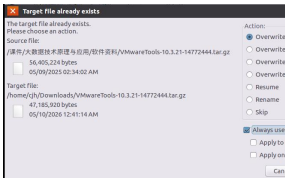

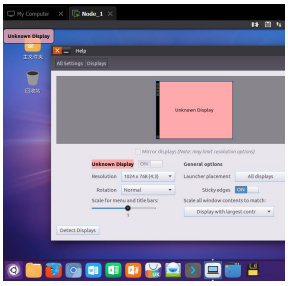

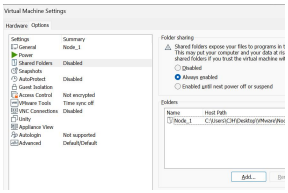

问题三详细说明

共享文件夹无法共享文件，改用 scp（SSH）传输文件。

```
Windows PowerShell
版权所有 (C)  Microsoft Corporation。保留所有权利。

安装最新的 PowerShell，了解新功能和改进！ https://aka.ms/PSWindows

PS C:\Users\CJH> scp "C:\Users\CJH\Desktop\VMware\Node_1\jdk-8u371-linux-x64.tar.gz" hadoop@192.168.88.128:/h
ome/hadoop/Downloads/
The authenticity of host '192.168.88.128 (192.168.88.128)' can't be established.
ED25519 key fingerprint is SHA256:WIJucCAzPP4SyZZbzpsv6oEh7jxZeud7jC5QVHzqgdc.
This key is not known by any other names.
Are you sure you want to continue connecting (yes/no/[fingerprint])?
Warning: Permanently added '192.168.88.128' (ED25519) to the list of known hosts.
hadoop@192.168.88.128's password:
jdk-8u371-linux-x64.tar.gz                                    100%  133MB  34.0MB/s   00:03
PS C:\Users\CJH>
```

附录：配置文件修改对比总览

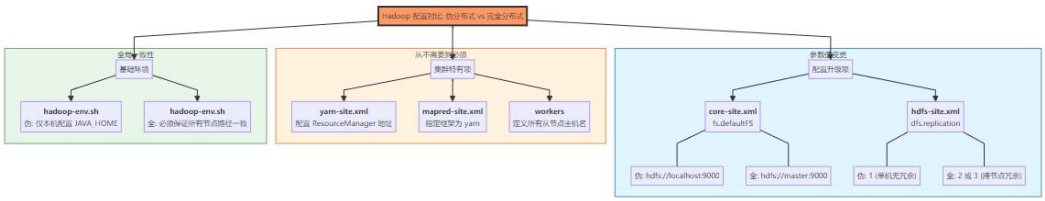

配置文件	在哪个节点修改	说明
core-site.xml	Master，然后 scp 到 Slave	所有节点需要相同的 fs.defaultFS 地址
hdfs-site.xml	Master，然后 scp 到 Slave	所有节点需要相同的副本数和存储路径
yarn-site.xml	Master，然后 scp 到 Slave	ResourceManager 在 Master；NodeManager 在 Slave 读取同一份配置去找 ResourceManager
mapred-site.xml	Master，然后 scp 到 Slave	所有节点统一指定 MapReduce 框架为 yarn
workers	仅 Master	只有 Master 的启动脚本会读取此文件
hadoop-env.sh	Master，然后 scp 到 Slave	必须写死 JAVA_HOME 的具体路径

完全分布式搭建流程

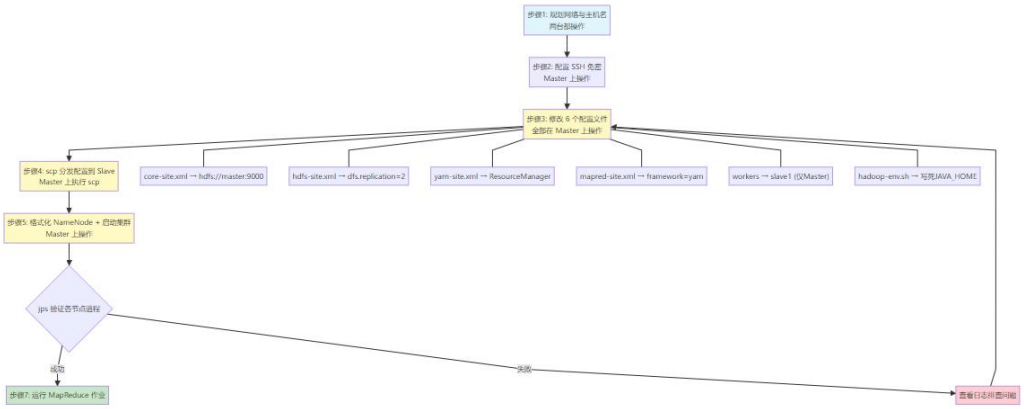

伪分布式配置流程

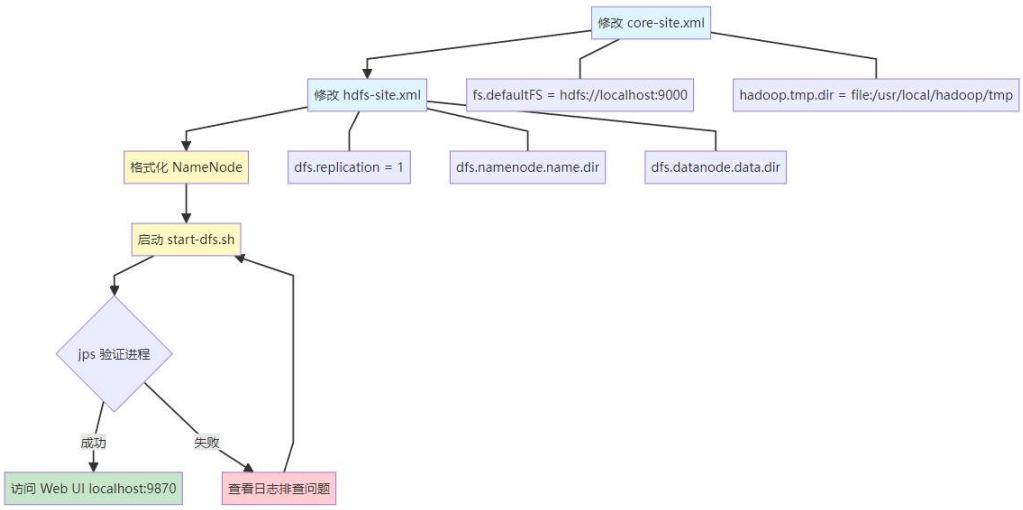

Hadoop 伪分布式架构

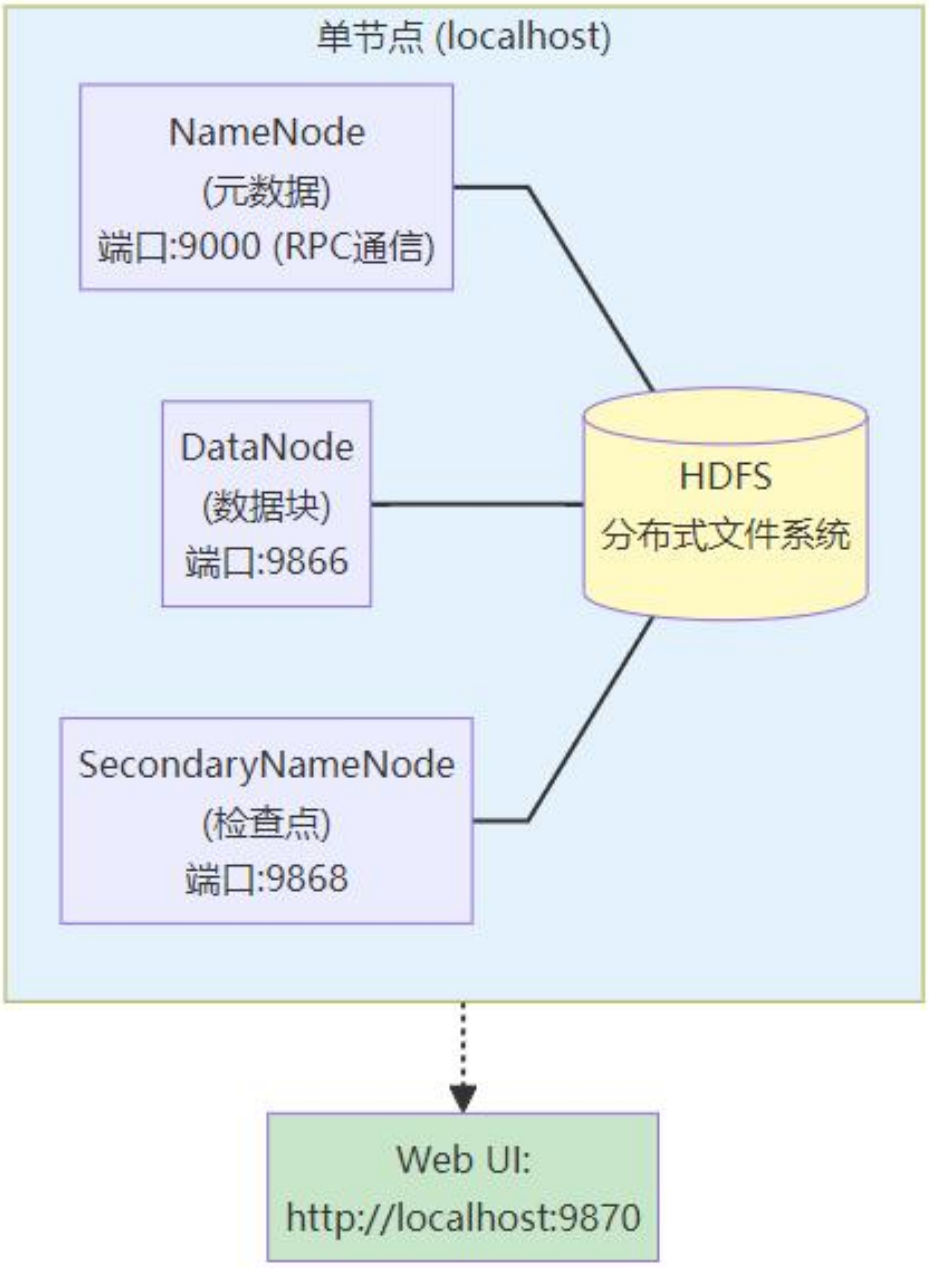

关键配置文件对照表

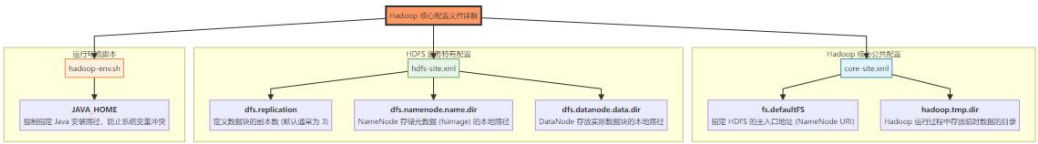

HDFS 常用操作命令速查

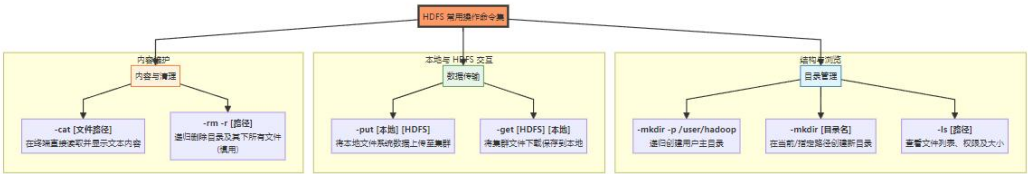

启动与停止命令

Hadoop 完全分布式架构

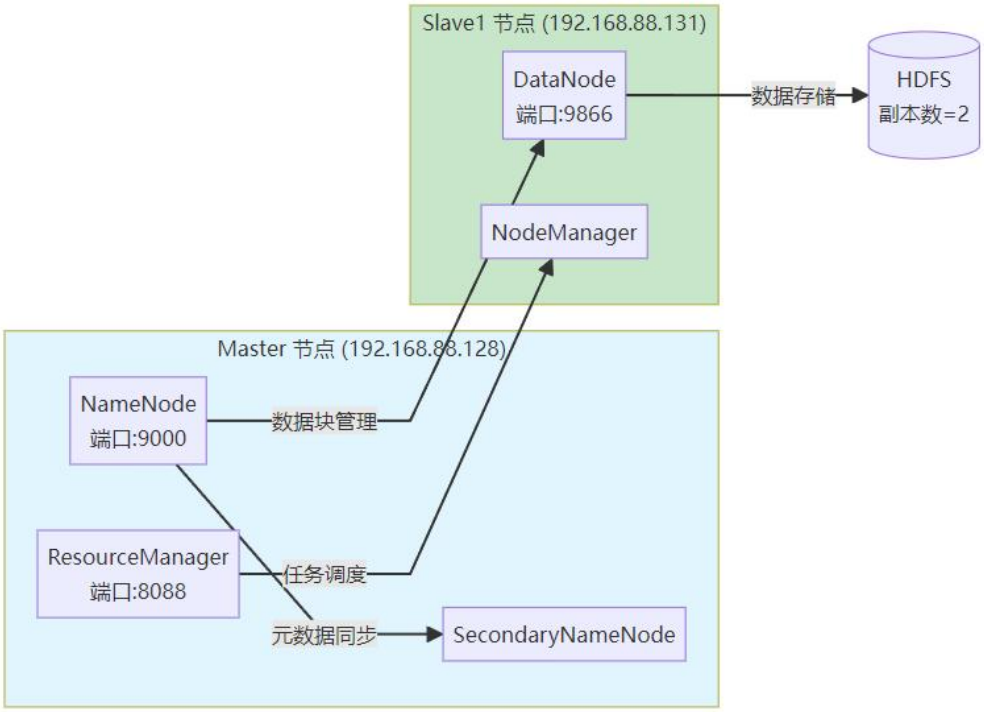

六、实验心得

通过本次实验，我完成了从 Linux 虚拟机安装到 Hadoop 完全分布式集群搭建的全过程。实验过程中遇到了许多问题，例如 SSH 免密登录配置、JAVA_HOME 环境变量设置、PID 文件残留导致启动失败等，通过查阅资料和反复调试逐一解决。

最大的收获是对 Hadoop 的架构有了更深入的理解：伪分布式模式下所有进程运行在同一台机器上，而完全分布式模式下 NameNode、ResourceManager 运行在 Master，DataNode、NodeManager 运行在 Slave，通过 SSH 和网络通信协调工作。配置文件的修改（如 core-site.xml 中的 fs.defaultFS 从 localhost 改为 master）体现了从单机到分布式的关键变化。

此外，实验中积累的排错经验（如查看日志、清理 PID 文件、检查 SSH 配置）对今后的系统运维工作有很大帮助。